САНКТ-ПЕТЕРБУРГСКИЙ НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО

Дисциплина: Инженерия данных

Отчет

Лабораторная работа 3
“Технология MapReduce”

Выполнила:

Автономова Ксения

J3313

Санкт-Петербург

2026 г.

Коротко о результате

56 044	34 498	8 584	1 141 214
вакансии варианта	вакансии с навыками	уникальных навыка	уникальных троек

В сегменте аналитических вакансий выделено 56 044 записи. Поле key_skills заполнено у 34 498 вакансий (61,6%). На полном сегменте MapReduce и DuckDB дали одинаковые результаты: 237 474 вхождения навыков, 1 032 848 вхождений пар и 3 985 980 вхождений троек. После фильтрации зарплатных данных осталось 19 078 наблюдений; медианная оценка зарплаты - 100 000 ₽.

1. Данные и методика

В исходном CSV - 229 388 строк; размер файла - 847 619 384 байта. Дубликатов по vacancy_id не обнаружено. Для варианта №10 использован фильтр по полю role: BI-аналитик/аналитик данных, аналитик, бизнес-аналитик, продуктовый аналитик, руководитель отдела аналитики и системный аналитик.

Этап	Что сделано
Подготовка навыков	Значения из key_skills разделены по «;», пробелы нормализованы, регистр приведён к нижнему. Дубли навыков внутри одной вакансии удалены, список отсортирован. Семантические синонимы не объединялись.
MapReduce	Объект читается из S3 потоково чанками по 5 000 исходных строк. На Map формируются локальные счётчики навыков, пар и троек; на Reduce они объединяются.
DuckDB	SQL обрабатывает тот же объект s3://hh-lake/data/it_vacancies_2024.csv; пары и тройки строятся по индексам элементов списка навыков.
Проверка	verify_results сравнивает ключи и частоты в файлах результатов для каждого размера выборки.

Для вакансии с k уникальными навыками число комбинаций равно C(k,2) = k(k−1)/2 для пар и C(k,3) = k(k−1) (k−2)/6 для троек. Поэтому количество троек растёт быстрее числа пар: при шести навыках одна вакансия даёт 15 пар и 20 троек. В среднем среди вакансий с заполненным списком навыков получилось 6,88 навыка, 29,94 пары и 115,54 тройки на вакансию.

2. Самые востребованные навыки



Десять наиболее частых навыков в сегменте аналитических вакансий

Навык	Вакансий	Навык	Вакансий
SQL	10 863	UML	4 802
Аналитическое мышление	8 337	Разработка технических заданий	4 518
BPMN	6 516	Работа с большим объёмом информации	4 457
Бизнес-анализ	6 029	Аналитика	3 949
Системный анализ	5 288	Анализ данных	5 197

SQL - наиболее частый отдельный навык. В верхней части списка также находятся аналитическое мышление, BPMN, бизнес-анализ и системный анализ. Это отражает несколько направлений внутри сегмента:

работу с данными, моделирование бизнес-процессов и формализацию требований.

3. Частоты пар и троек

На полном сегменте найдено 157 225 уникальных пар и 1 141 214 уникальных троек. Число уникальных комбинаций показывает их разнообразие; количество вхождений - сколько вакансий содержат соответствующую комбинацию.

Наиболее частые пары

Навык 1	Навык 2	Частота
BPMN	UML	3 910
BPMN	SQL	2 974
Python	SQL	2 750
SQL	UML	2 688
Анализ данных	Аналитическое мышление	2 568
SQL	Системный анализ	2 453
Аналитическое мышление	Работа с большим объёмом информации	2 285
BPMN	Системный анализ	2 263

Наиболее частые тройки

Навык 1	Навык 2	Навык 3	Частота
BPMN	SQL	UML	2 206
BPMN	UML	Системный анализ	1 720
BPMN	REST	UML	1 395
BPMN	SQL	Системный анализ	1 270
SQL	UML	Системный анализ	1 241
REST	SQL	UML	1 217
BPMN	REST	SQL	1 189
Анализ данных	Аналитическое мышление	Работа с большим объёмом информации	1 026

В обеих таблицах регулярно встречаются BPMN, SQL, UML и системный анализ. Для этого сегмента это ожидаемо: одни и те же

вакансии часто требуют описывать процессы, фиксировать требования и взаимодействовать с данными и системами.

4. Сверка MapReduce и DuckDB

После выравнивания порядка отбора первых N вакансий в SQL повторный запуск verify_results завершился со статусом verified = true. Совпали все строки и частоты по навыкам, парам и тройкам для каждого размера выборки.

Выборка	Строк навыков	Строк пар	Строк троек	Результат
1 000 вакансий	938	10 312	50 572	Совпало
5 000 вакансий	2 281	31 710	179 251	Совпало
10 000 вакансий	3 287	48 783	286 768	Совпало
Весь сегмент (56 044)	8 584	157 225	1 141 214	Совпало

(Это проверка двух независимых реализаций: сравнивались сами ключи комбинаций и соответствующие частоты, а не только итоговые суммы.)

5. Зарплаты и комбинации навыков

Для сравнения оставлены записи с валютой RUR. Если указаны обе границы зарплаты, использовалось их среднее; если только одна - эта граница. Значения ниже 10 000 и выше 1 000 000 ₽ исключены. После фильтра осталось 19 078 записей, медиана - 100 000 ₽. Минимальная поддержка: 20 наблюдений для навыка, 30 для пары и 20 для тройки.

Медиана по категориям роли

Категория role	Вакансий	С зарплатой	Медиана
Аналитик	30 112	11 746	80 000 ₽
Системный аналитик	10 609	2 762	166 250 ₽
Бизнес-аналитик	8 232	2 740	110 000 ₽
BI-аналитик, аналитик данных	3 969	987	105 000 ₽
Продуктовый аналитик	1 685	449	105 000 ₽
Руководитель отдела аналитики	1 437	394	130 000 ₽

Пары с более высокой медианой

Пара навыков	n	Медиана пары	База	Медиана базы	Δ
DWH + Анализ данных	36	250 000 ₽	Анализ данных	85 000 ₽	+165 000 ₽
JSON + Аналитика	33	250 000 ₽	Аналитика	100 000 ₽	+150 000 ₽
BPMN + Kafka	50	300 000 ₽	BPMN	150 000 ₽	+150 000 ₽
Kafka + SQL	58	280 000 ₽	SQL	135 000 ₽	+145 000 ₽
JSON + Аналитическое мышление	30	215 000 ₽	Аналитическое мышление	80 000 ₽	+135 000 ₽

Пары с более низкой медианой

Пара навыков	n	Медиана пары	База	Медиана базы	Δ
REST + Работа с базами данных	124	75 000 ₽	REST	200 000 ₽	−125 000 ₽
SOAP + Разработка ПО	49	75 000 ₽	SOAP	200 000 ₽	−125 000 ₽
SOAP + Экономический анализ	47	75 000 ₽	SOAP	200 000 ₽	−125 000 ₽
REST + Оптимизация бизнес-процессов	66	75 000 ₽	REST	200 000 ₽	−125 000 ₽
SOAP + Аналитический склад ума	52	75 000 ₽	SOAP	200 000 ₽	−125 000 ₽

Тройки с более высокой медианой

Тройка навыков	n	Медиана	Базовая пара	Медиана базы	Δ
Активные продажи + Навыки переговоров + Работа с большим объемом информации	24	325 000 ₽	Навыки переговоров + Работа с большим объемом информации	100 000 ₽	+225 000 ₽

Тройка навыков	n	Медиана	Базовая пара	Медиана базы	Δ
1С + ERP + Аналитика	22	337 500 ₽	1С + Аналитика	152 500 ₽	+185 000 ₽
1С: ERP + 1С: Документооборот + 1С: Предприятие 8	20	275 000 ₽	1С: Документооборот + 1С: Предприятие 8	100 000 ₽	+175 000 ₽
REST API + Scrum + SQL	20	280 000 ₽	Scrum + SQL	109 400 ₽	+170 600 ₽
JSON + SQL + Работа с базами данных	23	250 000 ₽	SQL + Работа с базами данных	81 000 ₽	+169 000 ₽

Тройки с более низкой медианой

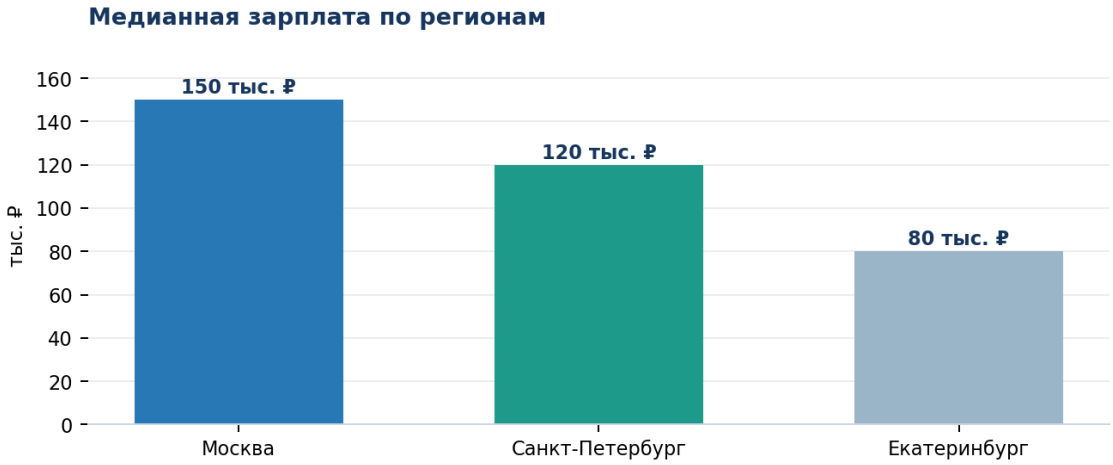
Тройка навыков	n	Медиана	Базовая пара	Медиана базы	Δ
Draw.io + UML + Анализ бизнес-процессов	21	80 000 ₽	Draw.io + UML	250 000 ₽	−170 000 ₽
BABok + Draw.io + UML	21	80 000 ₽	Draw.io + UML	250 000 ₽	−170 000 ₽
SOAP + System Analysis + UML	22	95 000 ₽	SOAP + UML	230 000 ₽	−135 000 ₽
Agile Project Management + SOAP + UML	21	95 000 ₽	SOAP + UML	230 000 ₽	−135 000 ₽
IDEF + SOAP + UML	21	95 000 ₽	SOAP + UML	230 000 ₽	−135 000 ₽

(Δ - разница между медианой комбинации и медианой базового навыка/пары. Это статистическая ассоциация, а не доказательство причинного влияния навыка на зарплату. На результат могут влиять роль, опыт, регион и тип работодателя.)

6. Региональный срез

Выбраны три региона с наибольшим числом вакансий в сегменте. Москва лидирует по объёму и медианной зарплате; Санкт-Петербург занимает промежуточное положение; Екатеринбург показывает самую

низкую медиану из трёх. Доля вакансий с заполненным списком навыков выше всего в Санкт-Петербурге - 64,5%.



Медианная зарплата в трёх наиболее представленных регионах

Регион	Вакансий	С навыками	Доля	С зарплатой	Медиана
Москва	27 452	16 551	60,3%	6 590	150 000 ₽
Санкт-Петербург	5 953	3 837	64,5%	1 910	120 000 ₽
Екатеринбург	2 268	1 353	59,7%	915	80 000 ₽

Самые частые навыки по регионам

Регион	Навык	Частота
Москва	SQL	6 199
Москва	BPMN	3 496
Москва	Аналитическое мышление	3 079
Москва	Бизнес-анализ	2 770
Москва	Системный анализ	2 689
Санкт-Петербург	SQL	1 161
Санкт-Петербург	Аналитическое мышление	886
Санкт-Петербург	Бизнес-анализ	771
Санкт-Петербург	BPMN	757
Санкт-Петербург	Системный анализ	623
Екатеринбург	Аналитическое мышление	398
Екатеринбург	SQL	370
Екатеринбург	Бизнес-анализ	266

Регион	Навык	Частота
Екатеринбург	BPMN	255
Екатеринбург	Анализ данных	252

Самые частые пары по регионам

Регион	Пара навыков	Частота
Москва	BPMN + UML	2 184
Москва	Python + SQL	1 749
Москва	BPMN + SQL	1 574
Москва	SQL + UML	1 428
Москва	SQL + Системный анализ	1 305
Санкт-Петербург	BPMN + UML	460
Санкт-Петербург	BPMN + SQL	350
Санкт-Петербург	SQL + UML	329
Санкт-Петербург	Python + SQL	327
Санкт-Петербург	SQL + Системный анализ	301
Екатеринбург	Анализ данных + Аналитическое мышление	139
Екатеринбург	BPMN + UML	118
Екатеринбург	SQL + Аналитическое мышление	112
Екатеринбург	Аналитическое мышление + Работа с большим объёмом информации	109
Екатеринбург	Аналитическое мышление + Бизнес-анализ	107

Самые частые тройки по регионам

Регион	Тройка навыков	Частота
Москва	BPMN + SQL + UML	1 195
Москва	BPMN + UML + Системный анализ	911
Москва	BPMN + REST + UML	805
Москва	BPMN + SQL + Системный анализ	664
Москва	BPMN + REST + SQL	657

Регион	Тройка навыков	Частота
Санкт-Петербург	BPMN + SQL + UML	270
Санкт-Петербург	BPMN + UML + Системный анализ	217
Санкт-Петербург	SQL + UML + Системный анализ	177
Санкт-Петербург	BPMN + SQL + Системный анализ	177
Санкт-Петербург	BPMN + REST + UML	157
Екатеринбург	BPMN + SQL + UML	68
Екатеринбург	BPMN + UML + Системный анализ	65
Екатеринбург	SQL + Анализ данных + Аналитическое мышление	62
Екатеринбург	Постановка задач разработчикам + Разработка технических заданий + Системный анализ	55
Екатеринбург	Анализ данных + Аналитическое мышление + Работа с большим объёмом информации	53

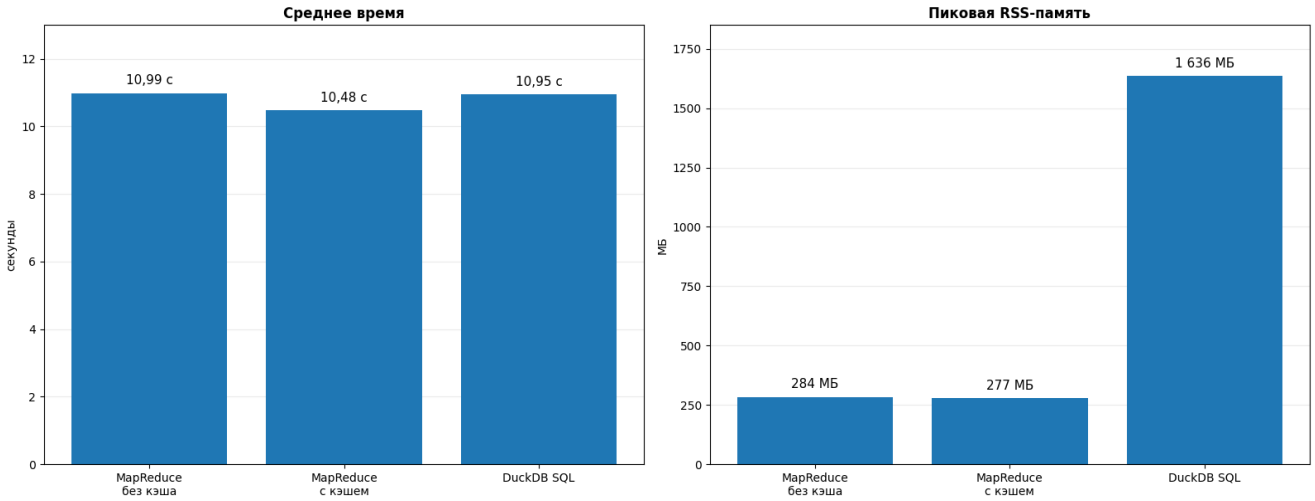
В Москве и Санкт-Петербурге чаще всего встречается SQL, а в Екатеринбурге на первом месте аналитическое мышление. BPMN + UML - самая частая пара в Москве и Санкт-Петербурге, а тройка BPMN + SQL + UML лидирует во всех трёх регионах. Медиана Москвы на 25% выше медианы Санкт-Петербурга и на 87,5% выше медианы Екатеринбурга.

7. Профилирование и оптимизация

Каждый метод запускался три раза на полном сегменте (56 044 вакансии) с чтением данных из RustFS/S3. Время измерялось как wall-clock time через time.perf_counter; RSS процесса опрашивалась psutil примерно каждые 0,05 секунды. В таблице приведён максимум RSS, замеченный за три попытки. Из-за интервала опроса кратковременный пик между измерениями мог не попасть в результат.

Метод	Попыток	Среднее, с	Мин. - макс., с	Пик RSS, МБ
MapReduce baseline (без кэша)	3	10,9862	10,6698 - 11,5693	283,95

Метод	Попыток	Среднее, с	Мин. - макс., с	Пик RSS, МБ
MapReduce optimized (с кэшем)	3	10,4818	10,3150 - 10,5653	277,27
DuckDB SQL	3	10,9530	10,9179 - 10,9719	1 636,08



Сравнение среднего времени и пикового потребления памяти

Кэш нормализации сократил среднее время MapReduce с 10,9862 до 10,4818 секунды, то есть на 0,5044 секунды (4,59%). Максимальная наблюдавшаяся RSS снизилась с 283,95 до 277,27 МБ (на 2,35%). Среднее время DuckDB составило 10,9530 секунды - это примерно на 4,50% больше, чем у оптимизированного MapReduce. При этом пиковая наблюдавшаяся RSS DuckDB была примерно в 5,90 раза выше. Результаты относятся к данному окружению и способу измерения; они не доказывают универсального преимущества одного инструмента.

8. Итоги

- В аналитический сегмент вошло 56 044 вакансии; хотя бы один навык указан в 34 498 вакансиях (61,6%). Чаще всего встречаются SQL (10 863), аналитическое мышление (8 337), BPMN (6 516), бизнес-анализ (6 029) и системный анализ (5 288).
- MapReduce и DuckDB совпали построчно по навыкам, парам и тройкам для всех четырёх размеров выборки: 1 000, 5 000, 10 000 вакансий и весь сегмент.

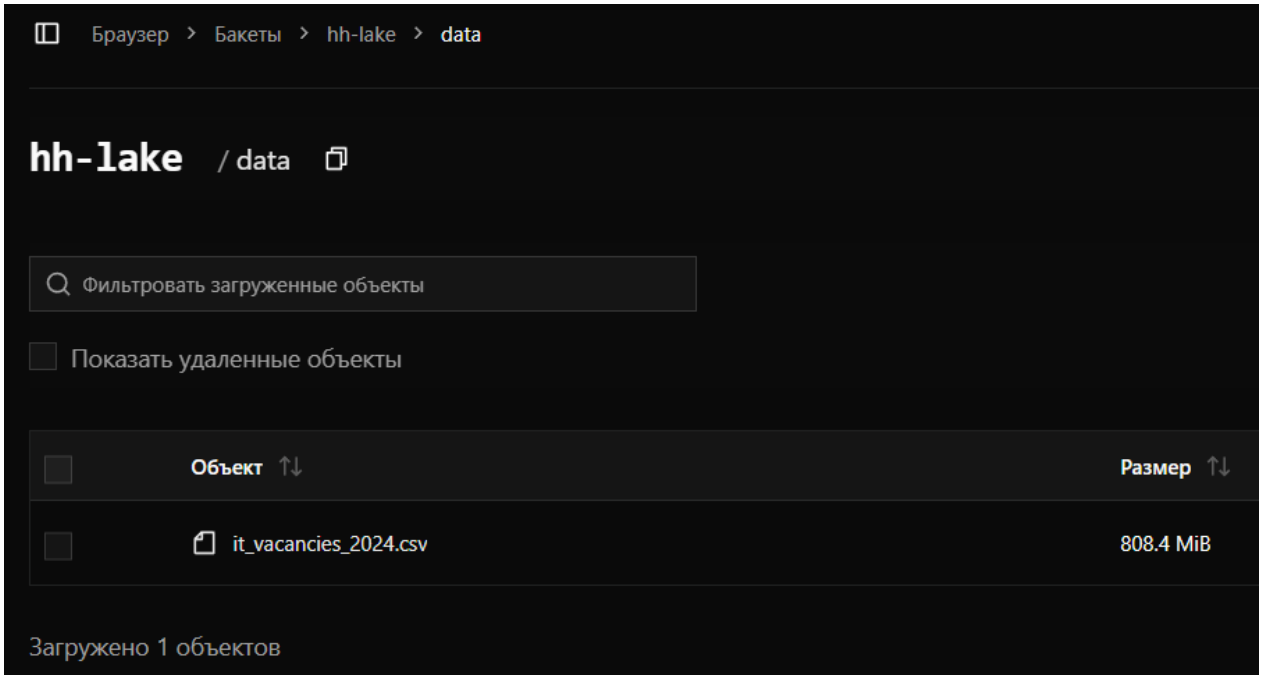
- После фильтрации зарплат осталось 19 078 наблюдений, медиана составила 100 000 ₽. Наибольшая положительная разница среди пар - DWH + Анализ данных: +165 000 ₽ (250 000 против 85 000 ₽). Наибольшая отрицательная - REST + Работа с базами данных: -125 000 ₽ (75 000 против 200 000 ₽).
- Среди троек наибольшая положительная разница получилась у сочетания Активные продажи + Навыки переговоров + Работа с большим объемом информации: +225 000 ₽. Наибольшая отрицательная - у Draw.io + UML + Анализ бизнес-процессов: -170 000 ₽. Эти результаты показывают статистическую связь, а не причинное влияние навыков на зарплату.
- Медианная зарплата составила 150 000 ₽ в Москве, 120 000 ₽ в Санкт-Петербурге и 80 000 ₽ в Екатеринбурге. Доля вакансий с указанными навыками выше всего в Санкт-Петербурге (64,5%). Кэш нормализации сократил среднее время MapReduce на 4,59%, а максимальную наблюдавшуюся RSS - на 2,35%.

Подтверждение выполнения

Ниже приведены скриншоты с локального запуска: наличие объекта в RustFS, совпадение результатов двух реализаций и результаты трёхкратного профилирования.

RustFS Console - объект в бакете hh-lake

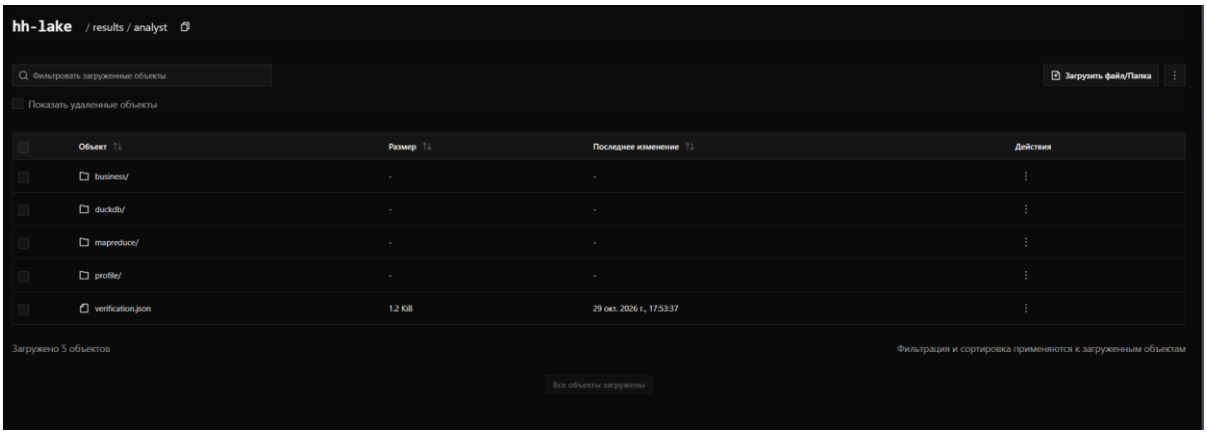
В бакете hh-lake виден объект data/it_vacancies_2024.csv. Консоль показывает размер около 808,4 MiB; точный размер, выведенный при загрузке, - 847 619 384 байта.



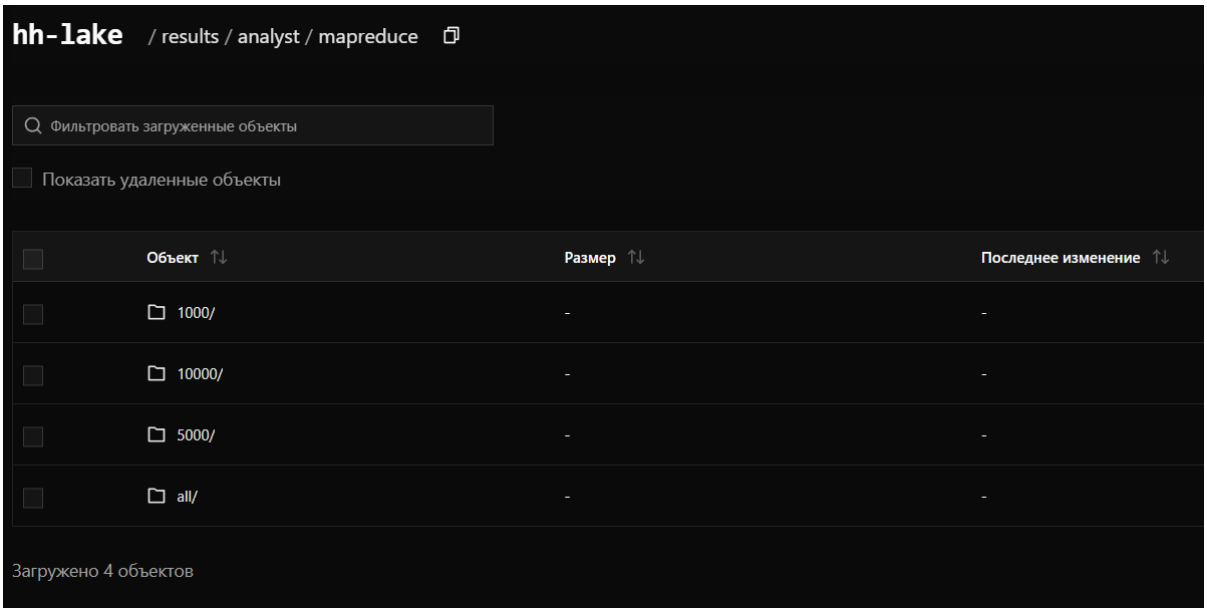
Объект data/it_vacancies_2024.csv в бакете hh-lake

Сохранение результатов обработки в RustFS

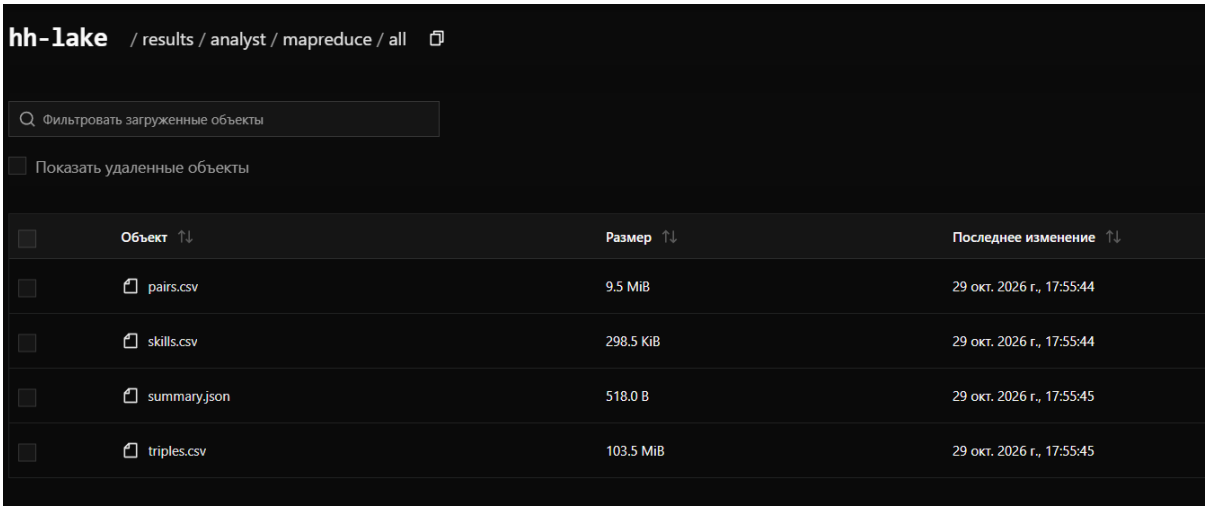
После выполнения расчетов результаты были загружены в бакет hh-lake по префиксу results/analyst. На скриншотах показаны структура каталогов и сохранённые файлы MapReduce, DuckDB, бизнес-анализа и профилирования.



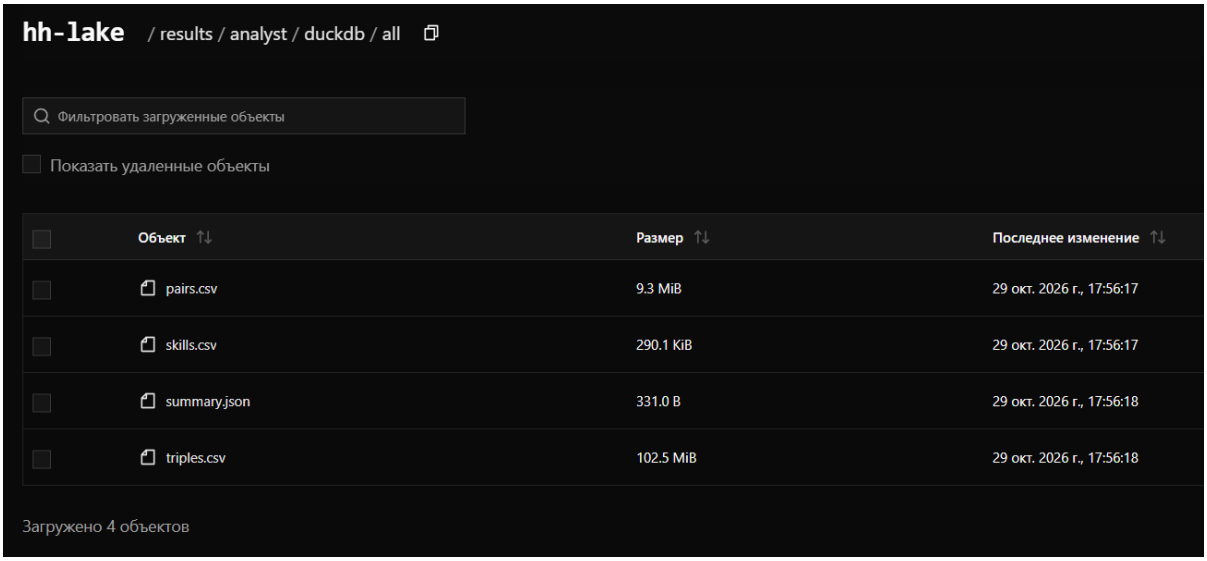
Структура префикса results/analyst в бакете hh-lake.



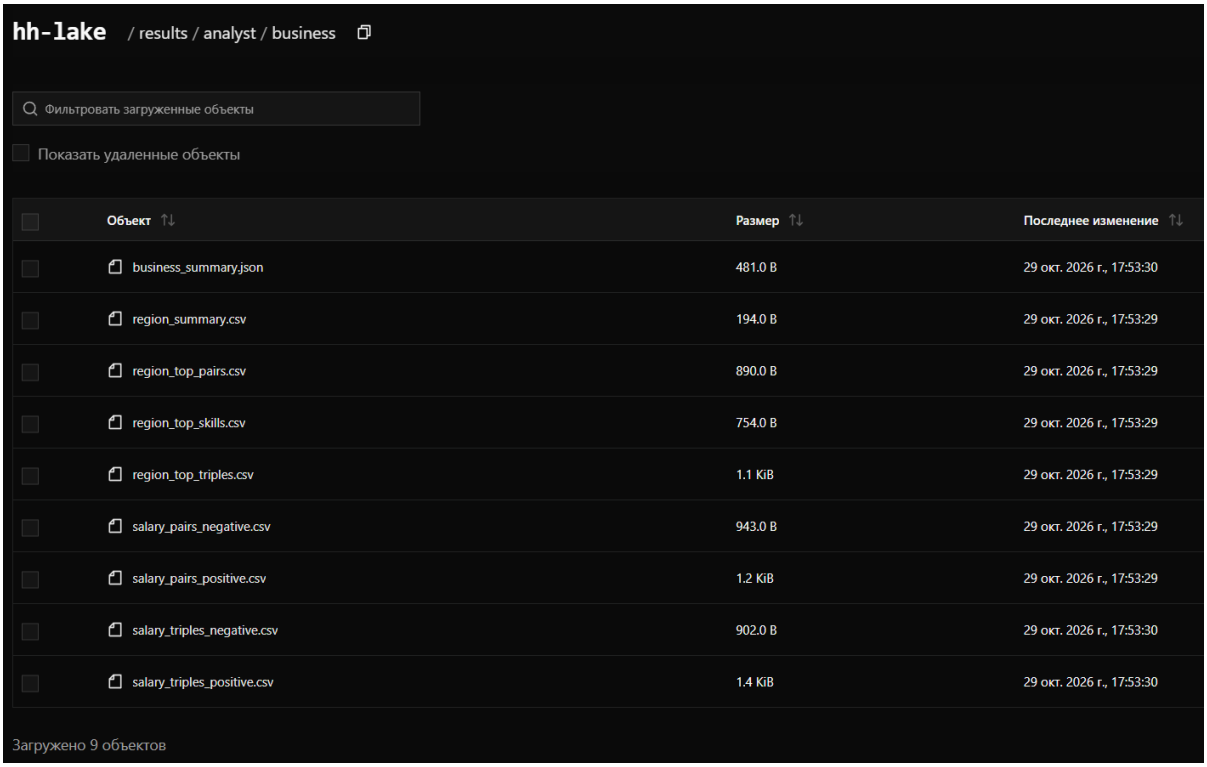
Каталоги MapReduce для выборок 1 000, 5 000, 10 000 и полного набора.



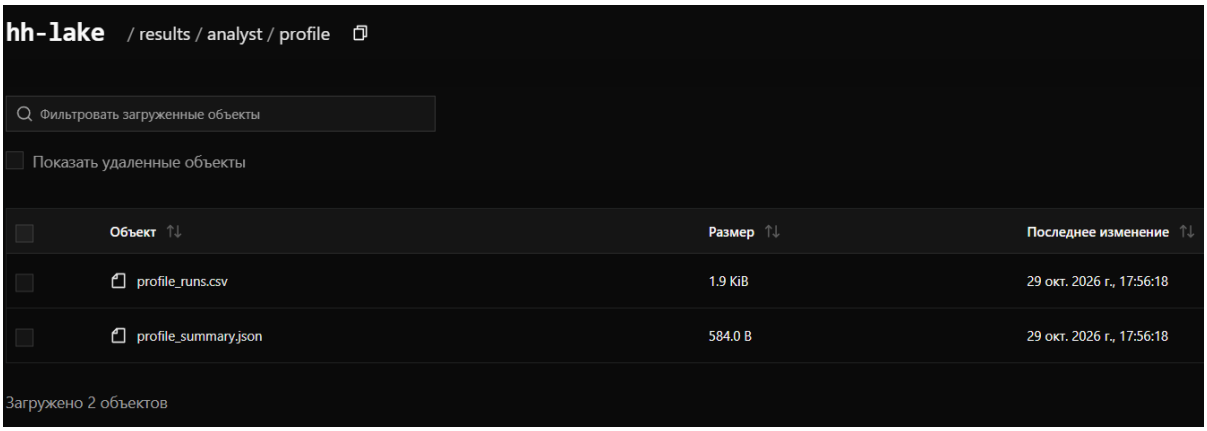
Файлы MapReduce для полного набора: skills.csv, pairs.csv, triples.csv и summary.json.



Файлы DuckDB для полного набора: skills.csv, pairs.csv, triples.csv и summary.json.



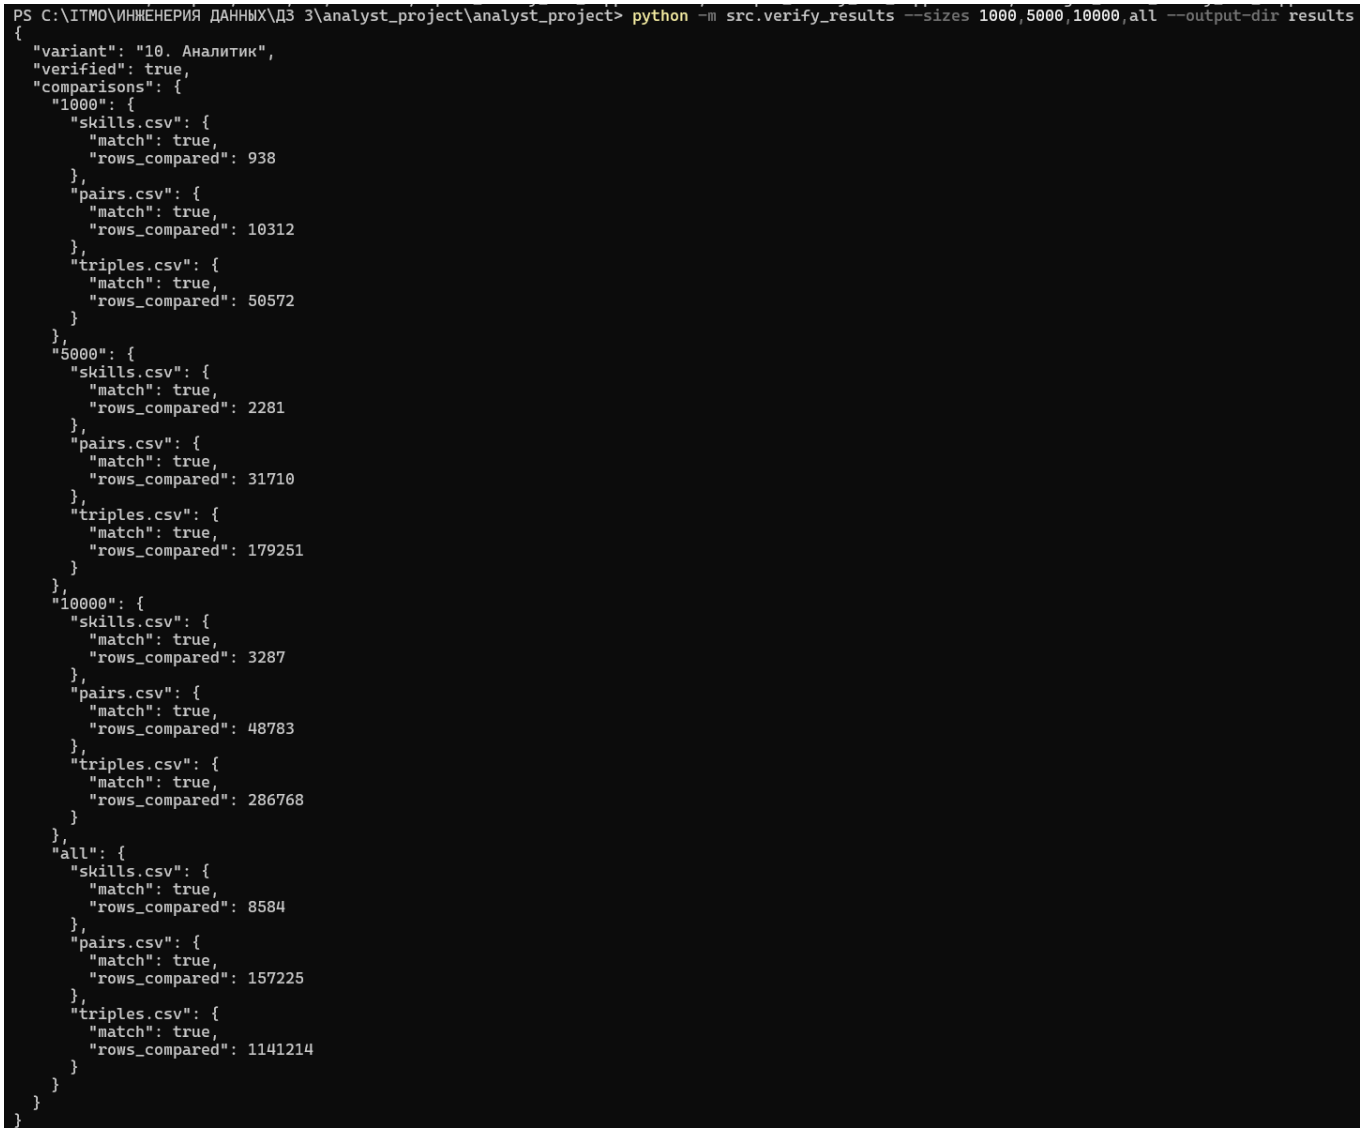
Результаты бизнес-анализа: сводка, региональные таблицы и таблицы влияния навыков на зарплату.



Результаты профилирования: profile_runs.csv и profile_summary.json.

Проверка совпадения результатов

Вывод verify_results содержит verified: true. Совпадение подтверждено для навыков, пар и троек на размерах 1 000, 5 000, 10 000 и на всём сегменте.



Результат построчного сравнения MapReduce и DuckDB

Профилирование: три попытки каждого метода

На рисунке приведены результаты трёх запусков каждого метода. Исходные значения взяты из profile_runs.csv, сводные показатели - из profile_summary.json.

Результаты профилирования

Три запуска каждого метода на полном сегменте

Метод	Время, с (попытки 1 / 2 / 3)	Среднее, с	RSS, МБ (попытки 1 / 2 / 3)	Пик RSS, МБ
MapReduce без кэша	10,7194 10,6698 11,5693	**10,9862**	283,95 283,82 283,55	**283,95**
MapReduce с кэшем	10,5650 10,3150 10,5653	**10,4818**	274,57 275,33 277,27	**277,27**
DuckDB SQL	10,9719 10,9179 10,9692	**10,9530**	1 634,22 1 634,61 1 636,08	**1 636,08**

Сводка profile_runs по трём попыткам

Команды для повторного запуска

Команды выполняются из корня проекта.

```
Copy-Item .env.example .env
python -m pip install -r requirements.txt
docker compose up -d rustfs
python -m src.upload_data --file data/it_vacancies_2024.csv --bucket hh-lake --key
data/it_vacancies_2024.csv
python -m src.run_all --sizes 1000,5000,10000,all --chunk-size 5000
python -m src.profile_runs --trials 3 --chunk-size 5000
```